


Qualité — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



40 différences significatives ; 29 flèches après réduction transitive. Holm (famille de 105 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Vitesse — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



68 différences significatives ; 36 flèches après réduction transitive. Holm (famille de 105 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Coût — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



85 différences significatives ; 32 flèches après réduction transitive. Holm (famille de 105 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Qualité / coût

Identités modèle × variante × effort · médianes par ticket, échecs de modèle inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (template)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (template)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (template)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (template)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j*** GLM 5.3 Flash
API OpenRouter · high
- k*** Mimo v2.6 Flash
API OpenRouter · medium
- l** GPT 6 Luna
API OpenAI · medium

Bleu / cercles : local ; vert / carrés : hébergé. Orange / creux / * : provisoire, sur les seules observations valides.
Axes de coût et de durée logarithmiques. Médianes marginales : ces distances ne remplacent pas les tests appariés.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Qualité / vitesse

Identités modèle × variante × effort · médianes par ticket, échecs de modèle inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (template)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (template)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (template)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (template)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j*** GLM 5.3 Flash
API OpenRouter · high
- k*** Mimo v2.6 Flash
API OpenRouter · medium
- l** GPT 6 Luna
API OpenAI · medium

Bleu / cercles : local ; vert / carrés : hébergé. Orange / creux / * : provisoire, sur les seules observations valides.
Axes de coût et de durée logarithmiques. Médianes marginales : ces distances ne remplacent pas les tests appariés.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Vitesse / coût

Identités modèle × variante × effort · médianes par ticket, échecs de modèle inclus



Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (template)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (template)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (template)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (template)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort template (non mesuré)
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j*** GLM 5.3 Flash
API OpenRouter · high
- k*** Mimo v2.6 Flash
API OpenRouter · medium
- l** GPT 6 Luna
API OpenAI · medium

Bleu / cercles : local ; vert / carrés : hébergé. Orange / creux / * : provisoire, sur les seules observations valides.
Axes de coût et de durée logarithmiques. Médianes marginales : ces distances ne remplacent pas les tests appariés.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Méthode et périmètre

Instantané UTC : 2026-10-06T17:58:04.551438+00:00. Cycles additifs : 17 identités, 10 tickets par identité. SpaceBunny et les essais préliminaires 0188 sont exclus. Les bras en rejeu sont isolés et marqués provisoires.

Unité statistique : le ticket (au plus 10 paires), pas les trois juges.

Qualité : somme des trois notes /30 ; DNF et soumission vide admissible = 0.

Vitesse : durée consommée ; un DNF au plafond garde ses 7 200 secondes.

Coût : API consommée, ou électricité locale à 0,23 EUR/kWh $\times$ 600 W, convertie à 1,08 USD/EUR.

Le coût local exclut matériel et amortissement : ce sont des coûts marginaux différents.

Test : Wilcoxon des rangs signés, bilatéral ; permutations exhaustives des signes (2^m).

Différences nulles exclues, rangs ex æquo moyens, arrondi des différences à 9 décimales.

Hypothèse : différences indépendantes entre tickets et symétriques autour de zéro sous H_0 .

La direction suit la somme des rangs signés ; aucune flèche tirée d'une simple différence de médianes.

Les pages principales utilisent $p < 0,05$ par comparaison. Les p ajustés de Holm, par axe, sont fournis dans le CSV ; les comptes ajustés figurent au bas des graphes. Avec 10 tickets et de nombreuses paires, la correction est peu puissante. Pas de flèche ne signifie pas égalité.

Réduction transitive : supprimer uniquement les liens déjà reliés par un autre chemin ; conserver toutes les comparaisons directes dans le CSV. La significativité n'est pas transitive. Les cycles, s'ils existent, restent visibles à l'intérieur de leurs composantes fortement connexes.

Les erreurs fournisseur/quota restent invalides et nécessitent un rejeu. Aucun score de modèle n'est déduit de ces erreurs. Instantané provisoire tant que GLM Flash et Mimo ne sont pas complets.

Source statistique : docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html