


Qualité / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Qualité / vitesse

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** **Claude Opus 5.5**
API Anthropic · medium
- d2** **Claude Opus 5.5**
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Vitesse / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 1 USD/h

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par ticket : coût total = coût direct + 1 × durée / 3 600 ; puis moyenne. Toute la durée est valorisée, DNF inclus.




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** MIMO v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Qualité — qui bat qui ?


Juste en haut · flèche vers Faux · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Vitesse — qui bat qui ?


Rapide en haut · flèche vers Lent · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Coût — qui bat qui ?

Abordable en haut · flèche vers Cher · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Méthode et périmètre

Échantillon aléatoire de 10 tickets tiré dans l'historique des projets de l'auteur.
Chaque modèle reprend les mêmes tâches depuis leur état antérieur à la résolution, avec les consignes du projet et une limite de deux heures par tentative.

Notation des résultats sur 30 selon le système de la boîte : trois juges partent de 10 et déduisent des points pour les fautes selon leur sévérité : -3 , -2 , -1 ou $-0,5$ point. Les juges examinent le travail sans connaître le modèle qui l'a produit. Une absence de résultat exploitable vaut zéro ; une impossibilité correctement expliquée est jugée normalement.

Le juge principal est Gemini 3.1 Pro Preview ; les deux autres sont Grok 4.3 et MiniMax M2.5. Les résultats conservés du premier cycle ont été jugés par Gemini 3.1 Pro Preview, DeepSeek V4 Pro et Kimi K3. Les notes sont additionnées, sans pondération entre juges.

Les modèles locaux tournent sur une Lenovo ThinkStation P620 : Ryzen Threadripper PRO 3945WX, 128 Go de RAM, deux GPU RTX A4000 + RTX 3060 (28 Go de VRAM au total). Le coût local estime l'électricité à 600 W et 0,23 €/kWh, sans amortissement du matériel. Les coûts API sont ceux des tokens consommés ; conversion commune : 1,08 USD pour 1 EUR.

Les nuages de points présentent les moyennes par ticket de qualité, durée et coût. Mistral Idéal retient le dernier résultat réussi de chaque ticket. Mistral beta additionne les coûts et durées de tous ses essais, interruptions comprises, et garde la meilleure note. Ses coûts sont répartis selon les tokens facturés ; les nouveaux essais restent estimés. La frontière de Pareto exclut les séries incomplètes et les qualités moyennes inférieures à 15/30.

Sur les trois graphes acycliques, les flèches comparent les résultats ticket par ticket par un test de Wilcoxon apparié, bilatéral, au seuil de 5 %. Elles vont vers le résultat moins juste, plus lent ou plus cher. Les flèches redondantes par transitivité sont retirées pour faciliter la lecture. L'absence de flèche ne prouve pas l'équivalence ; un chemin indirect n'est pas un test supplémentaire.

Le seuil de 5 % vaut pour chaque comparaison, sans garantie simultanée pour tout le graphe. La correction de Holm contrôle le risque de faux positifs lié aux comparaisons multiples. Avec dix tickets, aucune différence ne franchit ce seuil plus exigeant : les écarts détectés deux à deux ne constituent donc pas un classement global garanti à 95 %. Les astérisques signalent les séries provisoires ; les contours pointillés des DAG distinguent Qwen 3, Qwen 3.6, Sol 6 et Mistral beta.