

Qualité, vitesse et coût des LLM pour la recherche

Intercomparaison avec Pi, sur des tickets de projets utilisant Imperial Dragon Harness

Dix tickets tirés au hasard dans l'historique des projets de l'auteur.

Des modèles locaux et hébergés reprennent les mêmes tâches ; trois juges notent les résultats sur 30.

Nous comparons leur qualité, leur durée et leur coût, ainsi que le poids des incidents et des reprises.

Luna 6 medium : le meilleur compromis observé

Chez Claude comme chez ChatGPT, monter en gamme tout en réduisant l'effort ne donne pas ici d'avantage net : Opus 5.5 low face à Sonnet 5.5 medium, et Sol 6.1 low face à Luna 6 medium, offrent une qualité moyenne proche pour un coût supérieur. Sonnet est aussi plus rapide qu'Opus ; Luna fait jeu comparable avec Sol en vitesse. Limite : la mesure mélange orchestration-codage-revue.

Qwen 3.8 Flash-Next xhigh : une option locale pour privilégier la qualité

Avec Strata et la quantification IQ3_S, cette configuration obtient la meilleure note moyenne : 26,2/30, pour une durée moyenne de 46 minutes par ticket. Elle convient davantage au travail asynchrone. Son avance reste sensible à l'échantillon : sans le ticket 0333, sa moyenne rejoint celle de Mistral.

La configuration Qwen 3.8 locale atteint la qualité des références hébergées

La meilleure configuration Qwen 3.8 locale rejoint la qualité des références commerciales et progresse nettement sur Qwen 3.6. Le gain mêle génération, quantification, runtime et effort. Qwen tourne à xhigh, contre medium pour les références : davantage de verbosité et une durée accrue.

La lenteur et la sérialisation sur GPU limitent l'interactif en local

Sur la workstation de test, la lenteur et la nécessité de sérialiser les tâches sur les GPU limitent fortement l'usage interactif, tandis que les API permettent des flux de travail fortement parallélisés. Les attentes portent sur les modèles locaux éventuellement dérivés de Qwen 4 et Mistral 4, les mises à niveau du matériel et les optimisations quotidiennes du runtime, qui pourraient atténuer ces contraintes.

Mistral Large 4 : qualité prometteuse, fiabilité encore pénalisante

Mistral Large 4, annoncé le 6 octobre 2026, est prometteur en qualité, mais les incidents d'hébergement et les boucles observées dans son intégration au runtime Pi pénalisent encore sa fiabilité, sa vitesse et son coût.


Résultats par modèle

Modèle · variante / moteur · effort	Tentés	Réussis / 10	Qualité moyenne /30	Durée moyenne (min / ticket)	Coût moyen (USD / ticket)	Tokens générés moyens / ticket
a · Qwen 3.8 27B Q4_K_M · llama.cpp · xhigh (fixé côté serveur)	16	9 / 10	20,60	63,87	0,16	68 016
b · Qwen 3.8 Flash-Next IQ1_M · Strata · pruned · xhigh (fixé côté serveur)	14	10 / 10	21,10	39,41	0,10	64 702
b2 · Qwen 3.8 Flash-Next IQ3_S · Strata · xhigh (fixé côté serveur)	11	10 / 10	26,20	46,11	0,11	71 072
b3 · Qwen 3.8 Flash-Next Q2_0 · Strata · xhigh (fixé côté serveur)	10	9 / 10	20,75	39,73	0,10	71 416
c · Qwen 3.6 35B-A3B UD-Q4_K_XL · llama.cpp · effort non mesuré	10	10 / 10	10,30	10,21	0,03	24 584
c2 · Qwen 3.6 35B-A3B UD-Q4_K_XL · llama.cpp · effort non mesuré	10	9 / 10	8,95	9,15	0,02	11 477
d · Claude Opus 5.5 API Anthropic · medium	12	10 / 10	23,70	9,07	1,56	24 773
d2 · Claude Opus 5.5 API Anthropic · low	10	10 / 10	21,45	3,03	0,46	8 666
e · GPT 6 Sol API OpenAI · medium	10	10 / 10	18,05	4,91	0,39	7 548
e2 · GPT 6.1 Sol API OpenAI · low	10	10 / 10	22,65	5,15	0,21	4 687
e3 · GPT 6.1 Sol API OpenAI · medium	10	10 / 10	21,90	8,38	0,39	9 425
f · GLM 5.3 API Mistral · high	10	10 / 10	21,65	10,58	1,29	46 748
g · Claude Sonnet 5.5 API Anthropic · medium	10	10 / 10	21,35	2,09	0,30	8 896
i · DeepSeek Flash API DeepSeek · high	10	10 / 10	21,95	9,58	0,14	63 848
j · GLM 5.3 Flash API OpenRouter · high	15	9 / 10	21,60	26,96	0,31	46 654
k · Mimo v2.6 Flash API OpenRouter · medium	13	9 / 10	21,25	60,06	0,12	125 159
l · GPT 6 Luna API OpenAI · medium	10	10 / 10	22,20	5,02	0,04	16 052
mL · Mistral Large 4 · dernier succès API Mistral + OR (0874) · off	35	10 / 10	24,90	30,60	1,74	59 605
mA · Mistral Large 4 · toutes tentatives API Mistral + OR (0874) · off	35	10 / 10	24,90	96,32	6,36	196 233

Moyennes par ticket, échecs inclus ; les séries incomplètes portent sur les tickets évalués. Coût local : électricité seule. Mistral dernier succès : dix succès, dont 0874 via OpenRouter. Mistral toutes tentatives : mêmes notes, coûts et durées de 25 tentatives directes conservées, plus le remplacement OR de 0874 ; huit autres tentatives OR et un incident direct de configuration sont exclus. « Réussis » compte les tickets livrés, pas le nombre de tentatives. Les 9/10 correspondent à quatre dépassements du plafond de deux heures (a et b3 : 0874 ; j : 0333 ; k : 0211) et à une fin sans livraison valide (c2 : 0470). Ces échecs sont conservés à 0/30, avec leurs ressources consommées, plutôt que remplacés par une réussite après reprise ; le traitement particulier de Mistral est détaillé dans les limites.

Qualité / coût


Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique. Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / vitesse

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)**
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** **Claude Opus 5.5
API Anthropic · medium**
- d2** **Claude Opus 5.5
API Anthropic · low**
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol
API OpenAI · low**
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5
API Anthropic · medium**
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- I** **GPT 6 Luna
API OpenAI · medium**
- mL** **Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off**
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Vitesse / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique. Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 1 USD/(erg·h)

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par erg moyen : coût total = coût direct + 1 × durée / 3 600 ; puis moyenne. Durée en secondes, DNF inclus.



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** MIMO v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 0,10 EUR/(erg·h)

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par erg moyen : coût direct en USD / 1,08 + 0,10 × durée / 3 600 (secondes) ; puis moyenne. DNF inclus.




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- I** **GPT 6 Luna**
API OpenAI · medium
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique. Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité — qui bat qui ?


Juste en haut · flèche vers Faux · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Vitesse — qui bat qui ?


Rapide en haut · flèche vers Lent · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Coût — qui bat qui ?

Abordable en haut · flèche vers Cher · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Méthode et périmètre

Échantillon aléatoire de 10 tickets tiré dans l'historique des projets de l'auteur. Chaque modèle reprend les mêmes tâches depuis leur état antérieur à la résolution, avec les consignes du projet et une limite de deux heures par tentative.

Pi fournit le runtime d'agent : accès au modèle, appels d'outils et gestion de la session. Les tickets proviennent de projets utilisant Imperial Dragon Harness (IDH). Le prompt demande de respecter les consignes historiques de chaque dépôt (AGENTS.md, tickets/AGENTS.md et règles associées). Pour évaluer chaque modèle séparément, le tournoi désactive les revues externes et les panels Gaze, review-pr et verify-gate : le modèle réalise les tâches, exécute les contrôles mécaniques et effectue sa propre revue. Les trois juges interviennent seulement après la réalisation. Il s'agit donc d'une évaluation avec Pi et les consignes des projets, pas du workflow IDH complet.

Notation des résultats sur 30 selon le système de la boîte : trois juges partent de 10 et déduisent des points pour les fautes selon leur sévérité : -3, -2, -1 ou -0,5 point. Les juges examinent le travail sans connaître le modèle qui l'a produit. Une absence de résultat exploitable vaut zéro ; une impossibilité correctement expliquée est jugée normalement.

Le juge principal est Gemini 3.1 Pro Preview ; les deux autres sont Grok 4.3 et MiniMax M2.5. Les résultats conservés du premier cycle ont été jugés par Gemini 3.1 Pro Preview, DeepSeek V4 Pro et Kimi K3. Les notes sont additionnées, sans pondération entre juges.

Les modèles locaux tournent sur une Lenovo ThinkStation P620 : Ryzen Threadripper PRO 3945WX, 128 Go de RAM, deux GPU RTX A4000 + RTX 3060 (28 Go de VRAM au total). Le coût local estime l'électricité à 600 W et 0,23 €/kWh, sans amortissement du matériel. Les coûts API sont ceux des tokens consommés ; conversion commune : 1,08 USD pour 1 EUR.

Les nuages de points présentent les moyennes par ticket de qualité, durée et coût. Chaque ticket représente un erg moyen. La valeur du délai est exprimée par erg et par heure, en USD/(erg·h) ou EUR/(erg·h), et non comme un salaire horaire. Le coût pertinent est celui du résultat livré : les reprises consomment des ressources et retardent sa livraison. Mistral dernier succès retient le dernier résultat réussi de chaque ticket. Mistral toutes tentatives additionne les coûts et durées de 25 tentatives directes conservées et du succès OpenRouter sur 0874, interruptions comprises, et garde la meilleure note. Huit autres tentatives OpenRouter et une tentative directe invalidée pour configuration ne sont pas comptabilisées. Ses coûts sont répartis selon les tokens facturés ; les nouveaux essais restent estimés. La frontière de Pareto exclut les séries incomplètes et les qualités moyennes inférieures à 15/30.

En mai 2026, un benchmark d'inventaire des centrales thermiques au Vietnam, avec cinq répétitions par condition, montrait l'apport des sources et la répétabilité des modèles commerciaux. Ici, nous évaluons le travail livré avec outils, plutôt que l'exactitude d'un inventaire factuel.

- Pi : github.com/earendil-works/pi
- IDH : github.com/MinhHaDuong/ImperialDragonHarness
- Données et scripts du comparatif : version figée beta 0
- Benchmark de mai 2026 : Beyond RAG (présentation)

Méthode : comparaisons et limites

Sur les trois graphes acycliques, les flèches comparent les résultats ticket par ticket par un test de Wilcoxon apparié, bilatéral, au seuil de 5 %. Elles vont vers le résultat moins juste, plus lent ou plus cher. Les flèches redondantes par transitivité sont retirées pour faciliter la lecture. L'absence de flèche ne prouve pas l'équivalence ; un chemin indirect n'est pas un test supplémentaire.

Le seuil de 5 % vaut pour chaque comparaison, sans garantie simultanée pour tout le graphe. La correction de Holm contrôle le risque de faux positifs lié aux comparaisons multiples. Avec dix tickets et 120 comparaisons par graphe, ce seuil corrigé est hors d'atteinte du test utilisé, même lorsqu'un modèle gagne sur les dix tickets. L'absence de flèches après correction ne signifie donc pas que les modèles sont équivalents : cet échantillon ne permet pas d'établir les différences avec cette garantie globale. Mistral toutes tentatives a un contour pointillé dans les DAG. Qwen 3, Qwen 3.6 et GPT-6 Sol figurent seulement dans les nuages de points.

Limite : cette évaluation confie à un seul modèle l'ensemble du travail : orchestration, réalisation et revue de sa propre production. Elle mesure donc sa capacité à mener une tâche de bout en bout, plutôt que les performances d'un harnais qui choisit différents modèles selon les rôles et confie les revues à des modèles distincts pour réduire les erreurs corrélées. Les trois juges externes évaluent le résultat final ; ils ne participent pas à sa réalisation.

Limite : sur le ticket 0874, la dernière tentative directe avec Mistral a atteint le plafond de deux heures, malgré 195 réponses API réussies. Le modèle a longuement exploré le projet puis multiplié les tests, avec des modules et un hook manquants dans l'environnement. Le disjoncteur de répétitions identiques ne détecte pas cette dérive à commandes variables. Le résultat réussi via OpenRouter remplace ce ticket dans la série « dernier succès » ; Mistral toutes tentatives conserve les coûts et durées des tentatives directes échouées et ajoute ceux du remplacement. La série Mistral combine donc deux filières d'hébergement. Le coût OpenRouter est celui enregistré pour ce run ; les coûts directs suivent la calibration de la facture Mistral.

Limite : les séries usuelles retiennent les résultats après reprises, tandis que Mistral toutes tentatives cumule les essais. La répétabilité est la faible dispersion des résultats entre répétitions ; la réussite au premier essai est une autre forme de fiabilité. Les reprises hétérogènes empêchent ici de comparer uniformément cette dernière. La colonne « Tentés » compte les tentatives préservées, y compris celles invalidées pour infrastructure ou mauvais état de départ ; ces incidents ne sont pas tous imputables au modèle. Pour les deux lignes Mistral, ce compte couvre les deux fournisseurs, tandis que les coûts « toutes tentatives » suivent le périmètre documenté. Les tokens générés moyens suivent les runs retenus pour chaque série, et comprennent le reasoning quand il est inclus dans les tokens de sortie déclarés ; les tokenizers diffèrent entre fournisseurs.

Reprise b2 : les archives contiennent 11 tentatives pour les 10 tickets, dont une tentative 0333 interrompue par SIGTERM après 17 min 24 s (code de sortie 143). L'auteur a confirmé avoir demandé cette pause pour libérer le GPU pour un autre travail ; ce n'était pas un arrêt motivé par la qualité du résultat. Le rejeu retenu a obtenu 30/30 ; la tentative interrompue n'avait pas de note permettant un choix du meilleur score. Ce remplacement et ses ressources écartées empêchent de lire la série comme dix succès au premier essai. En retirant 0333 de toutes les séries, Qwen b2 et les deux séries Mistral ont chacun une qualité moyenne de 25,78/30 sur neuf tickets : b2 n'a alors plus seul la meilleure moyenne. « Tentés » est un compte des traces préservées, pas une garantie d'historique exhaustif.

La sélection des candidats est purement ad hoc, sans prétention à l'exhaustivité. Quels modèles, variantes ou runtimes souhaiteriez-vous voir dans le prochain comparatif ? Vos suggestions et retours sont bienvenus à minh.ha-duong@cnr.fr.