


Qualité — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



45 différences significatives ; 34 flèches après réduction transitive. Holm (famille de 153 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Vitesse — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



103 différences significatives ; 46 flèches après réduction transitive. Holm (famille de 153 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Coût — qui bat qui ?


Meilleur en haut · flèche vers le moins bon · Wilcoxon apparié exact · $p < 0,05$ bilatéral



120 différences significatives ; 43 flèches après réduction transitive. Holm (famille de 153 tests) : 0 flèches.
Seuil nominal par comparaison, sans garantie simultanée. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Qualité / coût


Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Cercle doré + nom complet : frontière de Pareto sur ces deux axes (identités complètes, qualité moyenne ≥ 15/30).
Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Qualité / vitesse


Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Cercle doré + nom complet : frontière de Pareto sur ces deux axes (identités complètes, qualité moyenne ≥ 15/30).
Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Vitesse / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Cercle doré + nom complet : frontière de Pareto sur ces deux axes (identités complètes, qualité moyenne ≥ 15/30).
Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Qualité / coût total — temps à 1 USD/h

Identités modèle $\times$ variante $\times$ effort $\cdot$ qualité, coût et durée moyens par ticket, échecs inclus

Par ticket : coût total = coût direct + 1 x durée / 3 600 ; puis moyenne. Toute la durée est valorisée, DNF inclus.



Cercle doré + nom complet : frontière de Pareto sur ces deux axes (identités complètes, qualité moyenne $\geq 15/30$).

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.

Coût local = électricité seule ; coût hébergé = API. Les graphiques de significativité utilisent uniquement les identités complètes.

Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** MIMO v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mß** Mistral Large 4 · beta
API Mistral direct · off

Méthode et périmètre

Instantané UTC : 2026-10-07T08:30:11.822662+00:00. Cycles additifs : 19 identités, 10 tickets par identité. SpaceBunny et les essais préliminaires 0188 sont exclus. Les bras en rejeu sont isolés et marqués provisoires.

Unité statistique : le ticket (au plus 10 paires), pas les trois juges.

Qualité : somme des trois notes /30 ; DNF et soumission vide admissible = 0.

Vitesse : durée consommée ; un DNF au plafond garde ses 7 200 secondes.

Coût : API consommée, ou électricité locale à 0,23 EUR/kWh $\times$ 600 W, convertie à 1,08 USD/EUR.

Le coût local exclut matériel et amortissement : ce sont des coûts marginaux différents.

Test : Wilcoxon des rangs signés, bilatéral ; permutations exhaustives des signes (2^m).

Différences nulles exclues, rangs ex æquo moyens, arrondi des différences à 9 décimales.

Hypothèse : différences indépendantes entre tickets et symétriques autour de zéro sous H_0 .

La direction suit la somme des rangs signés ; aucune flèche tirée d'une simple différence de médianes.

Les pages principales utilisent $p < 0,05$ par comparaison. Les p ajustés de Holm, par axe, sont fournis dans le CSV ; les comptes ajustés figurent au bas des graphes. Avec 10 tickets et de nombreuses paires, la correction est peu puissante. Pas de flèche ne signifie pas égalité.

Réduction transitive : supprimer uniquement les liens déjà reliés par un autre chemin ; conserver toutes les comparaisons directes dans le CSV. La significativité n'est pas transitive. Les cycles, s'ils existent, restent visibles à l'intérieur de leurs composantes fortement connexes.

Les erreurs fournisseur/quota restent invalides et nécessitent un rejeu. Aucun score de modèle n'est déduit de ces erreurs. Mistral Idéal : dernier succès ; réelle : tous les essais, meilleure note.

Coûts Mistral estimés aux tarifs EUR de lancement ; temps cumulés par ticket.

Source statistique : docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html