

Qualité, vitesse et coût des LLM pour la recherche

Intercomparaison avec Pi et Imperial Dragon Harness, 2026-10-07

Dix tickets tirés au hasard dans l'historique des projets de l'auteur.

Des modèles locaux et hébergés reprennent les mêmes tâches ; trois juges notent les résultats sur 30.

Nous comparons leur qualité, leur durée et leur coût, ainsi que le poids des incidents et des reprises.

Luna 6 medium : qualité et vitesse de Sol 6.1 low, en moins cher

Luna 6 medium fait jeu égal avec Sol 6.1 low en qualité et vitesse, en moins cher. Limite : la mesure mélange orchestration-codage-revue.

Qwen 3.8 Flash-Next xhigh avec Strata domine en non-interactif

Pour les tâches non interactives, Qwen 3.8 Flash-Next à effort xhigh, exécuté localement avec Strata, domine ce comparatif.

Qwen 3.8 local atteint la qualité des modèles commerciaux hébergés

Le saut générationnel entre Qwen 3.6 et Qwen 3.8 porte les modèles ouverts exécutés localement au niveau de qualité des modèles commerciaux hébergés sur les tâches de cet échantillon.

La lenteur et la sérialisation sur GPU limitent l'interactif en local


Sur la workstation testée, la lenteur et la nécessité de sérialiser les tâches sur les GPU limitent fortement l'usage interactif, tandis que les API permettent des flux de travail fortement parallélisés. Les attentes portent sur Qwen 4 et Mistral 4, les mises à niveau du matériel et les optimisations quotidiennes du runtime, qui pourraient atténuer ces contraintes.

Mistral Large 4 : qualité prometteuse, fiabilité encore pénalisante

Mistral Large 4, annoncé le 6 octobre 2026, est prometteur en qualité, mais les incidents d'hébergement et les boucles observées dans son intégration au runtime Pi pénalisent encore sa fiabilité, sa vitesse et son coût.

Qualité / coût

Identités modèle x variante x effort · qualité, coût et durée moyens par ticket, échecs inclus



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique. Coût local = électricité seule ; coût hébergé = API.

Source: minh.ha-duong@cnrs.fr, 2026-10-07

Qualité / vitesse


Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Vitesse / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 1 USD/h

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par ticket : coût total = coût direct + 1 × durée / 3 600 ; puis moyenne. Toute la durée est valorisée, DNF inclus.




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mi*** Mistral Large 4 · Idéal
API Mistral direct · off
- mβ** Mistral Large 4 · beta
API Mistral direct · off

Bleu : local ; vert : hébergé ; orange / creux / * : provisoire. Mistral : losange violet = Idéal, cercle rouge = beta. Coût et durée en échelle logarithmique.
Coût local = électricité seule ; coût hébergé = API.

Qualité — qui bat qui ?


Juste en haut · flèche vers Faux · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Vitesse — qui bat qui ?


Rapide en haut · flèche vers Lent · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Coût — qui bat qui ?

Abordable en haut · flèche vers Cher · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Ces flèches sont significatives deux à deux ; dix tickets ne suffisent pas à garantir le classement complet à 95 %.
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif. Détails p et n dans le CSV et les fichiers DOT.

Méthode et périmètre

Échantillon aléatoire de 10 tickets tiré dans l'historique des projets de l'auteur. Chaque modèle reprend les mêmes tâches depuis leur état antérieur à la résolution, avec les consignes du projet et une limite de deux heures par tentative.

Notation des résultats sur 30 selon le système de la boxe : trois juges partent de 10 et déduisent des points pour les fautes selon leur sévérité : -3, -2, -1 ou -0,5 point. Les juges examinent le travail sans connaître le modèle qui l'a produit. Une absence de résultat exploitable vaut zéro ; une impossibilité correctement expliquée est jugée normalement.

Le juge principal est Gemini 3.1 Pro Preview ; les deux autres sont Grok 4.3 et MiniMax M2.5. Les résultats conservés du premier cycle ont été jugés par Gemini 3.1 Pro Preview, DeepSeek V4 Pro et Kimi K3. Les notes sont additionnées, sans pondération entre juges.

Les modèles locaux tournent sur une Lenovo ThinkStation P620 : Ryzen Threadripper PRO 3945WX, 128 Go de RAM, deux GPU RTX A4000 + RTX 3060 (28 Go de VRAM au total). Le coût local estime l'électricité à 600 W et 0,23 €/kWh, sans amortissement du matériel. Les coûts API sont ceux des tokens consommés ; conversion commune : 1,08 USD pour 1 EUR.

Les nuages de points présentent les moyennes par ticket de qualité, durée et coût. Mistral Idéal retient le dernier résultat réussi de chaque ticket. Mistral beta additionne les coûts et durées de tous ses essais, interruptions comprises, et garde la meilleure note. Ses coûts sont répartis selon les tokens facturés ; les nouveaux essais restent estimés. La frontière de Pareto exclut les séries incomplètes et les qualités moyennes inférieures à 15/30.

Méthode : comparaisons et limites

Sur les trois graphes acycliques, les flèches comparent les résultats ticket par ticket par un test de Wilcoxon apparié, bilatéral, au seuil de 5 %. Elles vont vers le résultat moins juste, plus lent ou plus cher. Les flèches redondantes par transitivité sont retirées pour faciliter la lecture. L'absence de flèche ne prouve pas l'équivalence ; un chemin indirect n'est pas un test supplémentaire.

Le seuil de 5 % vaut pour chaque comparaison, sans garantie simultanée pour tout le graphe. La correction de Holm contrôle le risque de faux positifs lié aux comparaisons multiples. Avec dix tickets, aucune différence ne franchit ce seuil plus exigeant : les écarts détectés deux à deux ne constituent donc pas un classement global garanti à 95 %. Les astérisques signalent les séries provisoires ; Mistral beta a un contour pointillé dans les DAG. Qwen 3, Qwen 3.6 et GPT-6 Sol figurent seulement dans les nuages de points.

Limite : cette évaluation confie à un seul modèle l'ensemble du travail : orchestration, réalisation et revue de sa propre production. Elle mesure donc sa capacité à mener une tâche de bout en bout, plutôt que les performances d'un harnais qui choisit différents modèles selon les rôles et confie les revues à des modèles distincts pour réduire les erreurs corrélées. Les trois juges externes évaluent le résultat final ; ils ne participent pas à sa réalisation.

La sélection des candidats est purement ad hoc, sans prétention à l'exhaustivité. Quels modèles, variantes ou runtimes souhaiteriez-vous voir dans le prochain comparatif ? Vos suggestions et retours sont bienvenus à minh.ha-duong@cnr.fr.