

Qualité, vitesse et coût des LLM pour la recherche

Intercomparaison avec Pi, sur des tickets de projets utilisant Imperial Dragon Harness

Dix tickets tirés au hasard dans l'historique des projets de l'auteur.

Des modèles locaux et hébergés reprennent les mêmes tâches ; trois juges notent les résultats sur 30.

Nous comparons leur qualité, leur durée et leur coût, ainsi que le poids des incidents et des reprises.

Luna 6 medium : le meilleur compromis observé

Chez Claude comme chez ChatGPT, monter en gamme tout en réduisant l'effort ne donne pas ici d'avantage net : Opus 5.5 low face à Sonnet 5.5 medium, et Sol 6.1 low face à Luna 6 medium, offrent une qualité moyenne proche pour un coût supérieur. Sonnet est aussi plus rapide qu'Opus ; Luna fait jeu comparable avec Sol en vitesse. Haiku 5.5 : moyenne proche de Sonnet (21,70 contre 21,35/30), coût de 0,13 contre 0,30 USD, durée $\times 2,92$; équivalence non établie. Limite : un seul modèle tient les trois rôles, ce qui peut défavoriser un modèle conçu pour un seul.

Qwen 3.8 Flash-Next xhigh : une option locale pour privilégier la qualité

Avec Strata et la quantification IQ3_S, cette configuration obtient la meilleure note moyenne : 26,2/30, pour une durée moyenne de 46 minutes par ticket. Elle convient davantage au travail asynchrone. Son avance reste sensible à l'échantillon : sans le ticket 0333, sa moyenne rejoint celle de Mistral.

Qwen 3.8 local : une moyenne élevée face aux références hébergées

La meilleure configuration Qwen 3.8 locale obtient une note moyenne supérieure aux références hébergées et à Qwen 3.6 dans cet échantillon. Le gain mêle génération, quantification, runtime et effort. Qwen tourne à xhigh, contre medium pour les références : davantage de verbosité et une durée accrue.

La lenteur et la sérialisation sur GPU limitent l'interactif en local

Sur la workstation de test, la lenteur et la nécessité de sérialiser les tâches sur les GPU limitent fortement l'usage interactif, tandis que les API permettent des flux de travail fortement parallélisés. Les attentes portent sur les modèles locaux éventuellement dérivés de Qwen 4 et Mistral 4, les mises à niveau du matériel et les optimisations quotidiennes du runtime, qui pourraient atténuer ces contraintes.

Mistral Large 4 : qualité prometteuse, intégration et reprises coûteuses

Mistral Large 4, annoncé le 6 octobre 2026, est prometteur en qualité, mais les incidents d'hébergement et les boucles observées dans son intégration au runtime Pi pénalisent la configuration testée en durée et en coût ; la fiabilité propre du modèle n'est pas isolée.


Résultats par modèle

Modèle · variante / moteur · effort	Tentés	Réussis / 10	Qualité moyenne /30	Durée moyenne (min / ticket)	Coût moyen (USD / ticket)	Tokens générés moyens / ticket
a · Qwen 3.8 27B Q4_K_M · llama.cpp · xhigh (fixé côté serveur)	16	9 / 10	20,60	63,87	0,16	68 016
b · Qwen 3.8 Flash-Next Coder IQ1_M · Strata · pruned · xhigh (fixé côté serveur)	14	10 / 10	21,10	39,41	0,10	64 702
b2 · Qwen 3.8 Flash-Next IQ3_S · Strata · xhigh (fixé côté serveur)	11	10 / 10	26,20	46,11	0,11	71 072
b3 · Qwen 3.8 Flash-Next Q2_0 · Strata · xhigh (fixé côté serveur)	10	9 / 10	20,75	39,73	0,10	71 416
c · Qwen 3.6 35B-A3B UD-Q4_K_XL · llama.cpp · effort non mesuré	10	10 / 10	10,30	10,21	0,03	24 584
c2 · Qwen 3 Coder 30B-A3B UD-Q4_K_XL · llama.cpp · effort non mesuré	10	9 / 10	8,95	9,15	0,02	11 477
d · Claude Opus 5.5 API Anthropic · medium	12	10 / 10	23,70	9,07	1,56	24 773
d2 · Claude Opus 5.5 API Anthropic · low	10	10 / 10	21,45	3,03	0,46	8 666
e · GPT 6 Sol API OpenAI · medium	10	10 / 10	18,05	4,91	0,39	7 548
e2 · GPT 6.1 Sol API OpenAI · low	10	10 / 10	22,65	5,15	0,21	4 687
e3 · GPT 6.1 Sol API OpenAI · medium	10	10 / 10	21,90	8,38	0,39	9 425
f · GLM 5.3 API Mistral · high	10	10 / 10	21,65	10,58	1,29	46 748
g · Claude Sonnet 5.5 API Anthropic · medium	10	10 / 10	21,35	2,09	0,30	8 896
i · DeepSeek Flash API DeepSeek · high	10	10 / 10	21,95	9,58	0,14	63 848
j · GLM 5.3 Flash API OpenRouter · high	15	9 / 10	21,60	26,96	0,31	46 654
k · Mimo v2.6 Flash API OpenRouter · medium	13	9 / 10	21,25	60,06	0,12	125 159
l · GPT 6 Luna API OpenAI · medium	10	10 / 10	22,20	5,02	0,04	16 052
mL · Mistral Large 4 · dernier succès API Mistral + OR (0874) · off	35	10 / 10	24,90	30,60	1,74	59 605
mA · Mistral Large 4 · toutes tentatives API Mistral + OR (0874) · off	35	10 / 10	24,90	96,32	6,36	196 233
n · Claude Haiku 5.5 API Anthropic · medium	10	10 / 10	21,70	6,11	0,13	26 511

Moyennes par ticket, échecs inclus ; les séries incomplètes portent sur les tickets évalués. Coût local : électricité seule. Mistral dernier succès : dix succès, dont 0874 via OpenRouter. Mistral toutes tentatives : mêmes notes, coûts et durées de 25 tentatives directes conservées, plus le remplacement OR de 0874 ; huit autres tentatives OR et un incident direct de configuration sont exclus. « Réussis » compte les tickets livrés, pas le nombre de tentatives. Les 9/10 correspondent à quatre dépassements du plafond de deux heures (a et b3 : 0874 ; j : 0333 ; k : 0211) et à une fin sans livraison valide (c2 : 0470). Ces échecs sont conservés à 0/30, avec leurs ressources consommées, plutôt que remplacés par une réussite après reprise ; le traitement particulier de Mistral est détaillé dans les limites.

Qualité / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next IQ3_S · Strata · xhigh (fixé côté serveur)**
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna API OpenAI · medium**
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off
- n** Claude Haiku 5.5
API Anthropic · medium

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / vitesse

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Codex
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next**
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Codex 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** **Claude Opus 5.5**
API Anthropic · medium
- d2** **Claude Opus 5.5**
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol**
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mL** **Mistral Large 4 · dernier succès**
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off
- n** Claude Haiku 5.5
API Anthropic · medium

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Vitesse / coût

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** **Claude Sonnet 5.5**
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna**
API OpenAI · medium
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off
- n** Claude Haiku 5.5
API Anthropic · medium

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 1 USD/(erg·h)

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par erg moyen : coût total = coût direct + 1 × durée / 3 600 ; puis moyenne. Durée en secondes, DNF inclus.



Modèle · variante / moteur · effort


- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next IQ3_S · Strata · xhigh (fixé côté serveur)**
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** **GPT 6.1 Sol API OpenAI · low**
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna API OpenAI · medium**
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off
- n** Claude Haiku 5.5
API Anthropic · medium

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique. Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité / coût total — temps à 0,10 EUR/(erg·h)

Identités modèle × variante × effort · qualité, coût et durée moyens par ticket, échecs inclus

Par erg moyen : coût direct en USD / 1,08 + 0,10 × durée / 3 600 (secondes) ; puis moyenne. DNF inclus.




Modèle · variante / moteur · effort

- a** Qwen 3.8 27B
Q4_K_M · llama.cpp · xhigh (fixé côté serveur)
- b** Qwen 3.8 Flash-Next Coder
IQ1_M · Strata · pruned · xhigh (fixé côté serveur)
- b2** **Qwen 3.8 Flash-Next
IQ3_S · Strata · xhigh (fixé côté serveur)**
- b3** Qwen 3.8 Flash-Next
Q2_0 · Strata · xhigh (fixé côté serveur)
- c** Qwen 3.6 35B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- c2** Qwen 3 Coder 30B-A3B
UD-Q4_K_XL · llama.cpp · effort non mesuré
- d** Claude Opus 5.5
API Anthropic · medium
- d2** Claude Opus 5.5
API Anthropic · low
- e** GPT 6 Sol
API OpenAI · medium
- e2** GPT 6.1 Sol
API OpenAI · low
- e3** GPT 6.1 Sol
API OpenAI · medium
- f** GLM 5.3
API Mistral · high
- g** Claude Sonnet 5.5
API Anthropic · medium
- i** DeepSeek Flash
API DeepSeek · high
- j** GLM 5.3 Flash
API OpenRouter · high
- k** Mimo v2.6 Flash
API OpenRouter · medium
- l** **GPT 6 Luna
API OpenAI · medium**
- mL** Mistral Large 4 · dernier succès
API Mistral + OR (0874) · off
- mA** Mistral Large 4 · toutes tentatives
API Mistral + OR (0874) · off
- n** Claude Haiku 5.5
API Anthropic · medium

Bleu : local ; vert : hébergé. Mistral : losange violet = dernier succès, cercle rouge = toutes tentatives. Coût et durée en échelle logarithmique.
Anneau orange : frontière de Pareto (séries complètes, qualité moyenne ≥ 15/30). Coût local = électricité seule ; coût hébergé = API.

Qualité — qui bat qui ?


Juste en haut · flèche vers Faux · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Flèches au seuil nominal de 5 % ; aucune comparaison ne passe la correction de Holm (136 tests par axe).
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Vitesse — qui bat qui ?


Rapide en haut · flèche vers Lent · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Flèches au seuil nominal de 5 % ; aucune comparaison ne passe la correction de Holm (136 tests par axe).
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche ≠ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Coût — qui bat qui ?

Abordable en haut · flèche vers Cher · Wilcoxon apparié exact · $p < 0,05$ bilatéral



Flèches au seuil nominal de 5 % ; aucune comparaison ne passe la correction de Holm (136 tests par axe).
L'épaisseur des flèches traduit l'intensité de l'effet. Absence de flèche $\neq$ équivalence.
Un chemin indirect ne constitue pas un nouveau test significatif.

Méthode et périmètre

Échantillon aléatoire de 10 tickets tiré dans l'historique des projets de l'auteur. Chaque modèle reprend les mêmes tâches depuis leur état antérieur à la résolution, avec les consignes du projet et une limite de deux heures par tentative.

Pi fournit le runtime d'agent : accès au modèle, appels d'outils et gestion de la session. Les tickets proviennent de projets utilisant Imperial Dragon Harness (IDH). Le prompt demande de respecter les consignes historiques de chaque dépôt (AGENTS.md, tickets/AGENTS.md et règles associées). Pour évaluer chaque modèle séparément, le tournoi désactive les revues externes et les panels Gaze, review-pr et verify-gate : le modèle réalise les tâches, exécute les contrôles mécaniques et effectue sa propre revue. Les trois juges interviennent seulement après la réalisation. Il s'agit donc d'une évaluation avec Pi et les consignes des projets, pas du workflow IDH complet.

Notation des résultats sur 30 selon le système de la boîte : trois juges partent de 10 et déduisent des points pour les fautes selon leur sévérité : -3, -2, -1 ou -0,5 point. Les juges examinent le travail sans connaître le modèle qui l'a produit. Une absence de résultat exploitable vaut zéro ; une impossibilité correctement expliquée est jugée normalement.

Le juge principal est Gemini 3.1 Pro Preview ; les deux autres sont Grok 4.3 et MiniMax M2.5. Les résultats conservés du premier cycle ont été jugés par Gemini 3.1 Pro Preview, DeepSeek V4 Pro et Kimi K3. Les notes sont additionnées, sans pondération entre juges.

Les modèles locaux tournent sur une Lenovo ThinkStation P620 : Ryzen Threadripper PRO 3945WX, 128 Go de RAM, deux GPU RTX A4000 + RTX 3060 (28 Go de VRAM au total). Le coût local estime l'électricité à 600 W et 0,23 €/kWh, sans amortissement du matériel. Les coûts API sont ceux des tokens consommés ; conversion commune : 1,08 USD pour 1 EUR.

Les nuages de points présentent les moyennes par ticket de qualité, durée et coût. Chaque ticket représente un erg moyen. La valeur du délai est exprimée par erg et par heure, en USD/(erg·h) ou EUR/(erg·h), et non comme un salaire horaire. Le coût pertinent est celui du résultat livré : les reprises consomment des ressources et retardent sa livraison. Mistral dernier succès retient le dernier résultat réussi de chaque ticket, aussi le meilleur sur les trois tickets repris. Mistral toutes tentatives additionne les coûts et durées de 25 tentatives directes conservées et du succès OpenRouter sur 0874, interruptions comprises, et garde la meilleure note. Huit autres tentatives OpenRouter et une tentative directe invalidée pour configuration ne sont pas comptabilisées. Ses coûts sont répartis selon les tokens facturés ; les nouveaux essais restent estimés. La frontière de Pareto exclut les séries incomplètes et les qualités moyennes inférieures à 15/30.

En mai 2026, un benchmark d'inventaire des centrales thermiques au Vietnam, avec cinq répétitions par condition, montrait l'apport des sources et la répétabilité des modèles commerciaux. Ici, nous évaluons le travail livré avec outils, plutôt que l'exactitude d'un inventaire factuel.

- Pi : github.com/earendil-works/pi
- IDH : github.com/MinhHaDuong/ImperialDragonHarness
- Données du comparatif : instantané figé du 8 octobre 2026
- Benchmark de mai 2026 : Beyond RAG (présentation)

Méthode : comparaisons et limites

Sur les trois graphes acycliques, les flèches comparent les résultats ticket par ticket par un test de Wilcoxon apparié, bilatéral, au seuil de 5 %. Elles vont vers le résultat moins juste, plus lent ou plus cher. Les flèches redondantes par transitivité sont retirées pour faciliter la lecture. L'absence de flèche ne prouve pas l'équivalence ; un chemin indirect n'est pas un test supplémentaire.

Le seuil de 5 % vaut pour chaque comparaison, sans garantie simultanée pour tout le graphe. La correction de Holm contrôle le risque de faux positifs lié aux comparaisons multiples. Avec dix tickets et 136 comparaisons par graphe, ce seuil corrigé est hors d'atteinte du test utilisé, même lorsqu'un modèle gagne sur les dix tickets. L'absence de flèches après correction ne signifie donc pas que les modèles sont équivalents : cet échantillon ne permet pas d'établir les différences avec cette garantie globale. Mistral toutes tentatives a un contour pointillé dans les DAG. Qwen 3, Qwen 3.6 et GPT-6 Sol figurent seulement dans les nuages de points.

Limite : cette évaluation confie à un seul modèle l'ensemble du travail : orchestration, réalisation et revue de sa propre production. Elle mesure donc sa capacité à mener une tâche de bout en bout, plutôt que les performances d'un harnais qui choisit différents modèles selon les rôles et confie les revues à des modèles distincts pour réduire les erreurs corrélées. Ce choix peut défavoriser un exécutant tel Haiku 5.5, ou tout modèle plus à l'aise dans un seul rôle ; le test ne le mesure pas. Les trois juges externes évaluent le résultat final sans y participer.

Limite : sur le ticket 0874, la dernière tentative directe avec Mistral a atteint le plafond de deux heures, malgré 195 réponses API réussies. Le modèle a longuement exploré le projet puis multiplié les tests, avec des modules et un hook manquants dans l'environnement. Le disjoncteur de répétitions identiques ne détecte pas cette dérive à commandes variables. Le résultat réussi via OpenRouter remplace ce ticket dans la série « dernier succès » ; Mistral toutes tentatives conserve les coûts et durées des tentatives directes échouées et ajoute ceux du remplacement. La série Mistral combine donc deux filières d'hébergement. Le coût OpenRouter est celui enregistré pour ce run ; les coûts directs suivent la calibration de la facture Mistral.

Limite : les séries usuelles retiennent les résultats après reprises, tandis que Mistral toutes tentatives cumule les essais. La répétabilité est la faible dispersion des résultats entre répétitions ; la réussite au premier essai est une autre forme de fiabilité. Les reprises hétérogènes empêchent ici de comparer uniformément cette dernière. La colonne « Tentés » compte les tentatives préservées, y compris celles invalidées pour infrastructure ou mauvais état de départ ; ces incidents ne sont pas tous imputables au modèle. Pour les deux lignes Mistral, ce compte couvre les deux fournisseurs, tandis que les coûts « toutes tentatives » suivent le périmètre documenté. Les tokens générés moyens suivent les runs retenus pour chaque série, et comprennent le reasoning quand il est inclus dans les tokens de sortie déclarés ; les tokenizers diffèrent entre fournisseurs.

Reprise b2 : les archives contiennent 11 tentatives pour les 10 tickets, dont une tentative 0333 interrompue par SIGTERM après 17 min 24 s (code de sortie 143). L'auteur a confirmé avoir demandé cette pause pour libérer le GPU pour un autre travail ; ce n'était pas un arrêt motivé par la qualité du résultat. Le rejeu retenu a obtenu 30/30 ; la tentative interrompue n'avait pas de note permettant un choix du meilleur score. Ce remplacement et ses ressources écartées empêchent de lire la série comme dix succès au premier essai. En retirant 0333 de toutes les séries, Qwen b2 et les deux séries Mistral ont chacun une qualité moyenne de 25,78/30 sur neuf tickets : b2 n'a alors plus seul la meilleure moyenne. « Tentés » est un compte des traces préservées, pas une garantie d'historique exhaustif.

La sélection des candidats est purement ad hoc, sans prétention à l'exhaustivité. Quels modèles, variantes ou runtimes souhaiteriez-vous voir dans le prochain comparatif ? Vos suggestions et retours sont bienvenus à minh.ha-duong@cnsr.fr.

Annexe technique auto-générée

Analyses complémentaires et guide de choix

Résultats figés du 8 octobre ; complément rédigé le 9 octobre. Guide relu par un relecteur délégué (Fable) à la demande de l'auteur.

Résumé exécutif

H1 ne se vérifie pas : Sol low n'est pas plus rapide que Sonnet medium. H2 est hétérogène : Luna a une durée moyenne inférieure aux six configurations locales, mais l'égalité de qualité n'est pas démontrée et IQ3_S garde une meilleure moyenne. Les différences d'effort ne prouvent pas une dominance de qualité. Les groupes de routage sont des choix opérationnels, pas des clusters statistiques estimés.

Sommaire du rapport complété

Pages 1-12 : synthèse, résultats, cinq nuages, trois DAG, méthode et limites. Page 13 : titre de l'annexe technique. Page 15 : grille, médianes et Pareto 3D. Pages 16-17 : verdicts appariés. Pages 18-22 : distributions de treize comparaisons. Page 23 : analyse des classes. Page 24 : événements historiques et corrections. Pages 25-26 : guide situationnel, quotas et tarification. Page 27 : provenance et couverture du ticket.

Statut et licence

Préparé par ChatGPT puis finalisé par Claude Opus 5.5, à la demande de Ha-Duong Minh. Licence science ouverte : CC BY 4.0 (réutilisation libre avec attribution). Message : aucun classement ne survit à la correction de Holm ; choisir d'abord selon les contraintes (confidentialité, délai, budget, GPU, quotas), puis selon le compromis observé. Le guide ci-dessous n'est pas une décision de routage appliquée.

Grille et frontière de Pareto en trois dimensions

Médianes marginales : elles ne remplacent pas les différences appariées. Chaque identité comprend modèle, effort et runtime.

Série	Configuration (effort : légendes)	Q méd.	Q moy.	Min méd.	USD méd.
a	Qwen 3.8 27B	22,75	20,60	51,97	0,1291
b	Qwen 3.8 Flash-Next Coder	21,25	21,10	31,30	0,0778
b2	Qwen 3.8 Flash-Next	26,50	26,20	42,87	0,1065
b3	Qwen 3.8 Flash-Next	24,00	20,75	33,13	0,0823
c	Qwen 3.6 35B-A3B	9,25	10,30	6,52	0,0162
c2	Qwen 3 Coder 30B-A3B	8,50	8,95	5,62	0,0140
d	Claude Opus 5.5	26,50	23,70	5,99	0,8003
d2	Claude Opus 5.5	22,75	21,45	2,82	0,3066
e	GPT 6 Sol	16,00	18,05	3,53	0,3731
e2	GPT 6.1 Sol	23,25	22,65	5,10	0,2066
e3	GPT 6.1 Sol	25,00	21,90	9,40	0,3349
f	GLM 5.3	22,00	21,65	8,71	0,5242
g	Claude Sonnet 5.5	21,00	21,35	1,13	0,1544
i	DeepSeek Flash	20,50	21,95	10,15	0,1059
j	GLM 5.3 Flash	26,00	21,60	10,39	0,1694
k	Mimo v2.6 Flash	23,00	21,25	44,89	0,0808
l	GPT 6 Luna	21,75	22,20	3,84	0,0278
n	Claude Haiku 5.5	22,50	21,70	3,03	0,0227
mi	Mistral Large 4 · dernier succès	25,75	24,90	30,46	1,2062
mr	Mistral Large 4 · toutes tentatives	25,75	24,90	77,02	2,1511

Pareto 3D sur les moyennes, séries complètes avec qualité $\geq 15/30$: b2, d, d2, e2, g, l, mi. Une série est dominée si une autre est au moins aussi bonne en qualité, au plus aussi longue et aussi chère, avec une amélioration stricte. Il s'agit d'une frontière descriptive, sans garantie statistique.

Verdicts appariés : H1 et H2

Lecture A / B : gains de qualité, égalités, pertes ; médiane ΔQ ; ratios médians A/B. Ratio <1 = moins de ressources.

Question : A/B	G/E/P	ΔQ	Durée	Coût	p Q	Holm Q	Dom. /10
H1 e2/g	4/1/5	-0,25	3,53	0,97	0,5703	1,0000	0
H2-a l/a	5/0/5	-0,00	0,08	0,21	0,9805	1,0000	5
H2-b l/b	4/0/6	-1,25	0,13	0,27	0,8418	1,0000	4
H2-b2 l/b2	1/2/7	-2,75	0,11	0,25	0,0156	1,0000	3
H2-b3 l/b3	5/1/4	1,00	0,16	0,33	0,8438	1,0000	5
H2-c l/c	9/1/0	10,00	0,58	1,25	0,0039	0,6992	3
H2-c2 l/c2	10/0/0	13,00	0,58	2,26	0,0020	0,3711	4

H1

Hypothèse initiale : Sol 6.1 low domine Sonnet medium sur les trois axes. Les moyennes donnent +1,30 point en qualité et un coût inférieur, mais une durée supérieure. La domination conjointe postulée n'est pas observée ; aucune équivalence ou supériorité de qualité n'est établie.

H2

Luna est plus rapide sur 10/10 tickets face à a, b, b2 et b3, sur 6/10 face à c et 9/10 face à c2. La qualité dépend du comparateur : sa moyenne dépasse celles des anciennes configurations, mais reste inférieure à IQ3_S. Sans marge d'équivalence préenregistrée, « qualité égale » ne peut pas être confirmé. « Coût négligeable » n'avait pas de seuil numérique.

Effort, variantes et comparaisons inter-camps

Lecture A / B : gains de qualité, égalités, pertes ; médiane ΔQ ; ratios médians A/B. Ratio <1 = moins de ressources.

Question : A/B	G/E/P	ΔQ	Durée	Coût	p Q	Holm Q	Dom. /10
Sol effort e2/e3	5/0/5	0,00	0,63	0,63	0,9453	1,0000	5
Opus effort d2/d	4/1/5	-0,50	0,38	0,33	0,5156	1,0000	5
Local / hosted b2/e3	7/2/1	3,00	4,76	0,29	0,0234	1,0000	0
GLM / Flash f/j	3/0/7	-1,75	0,44	3,91	0,4414	1,0000	0
IQ3_S / Q2_0 b2/b3	8/2/0	3,50	1,29	1,29	0,0078	1,0000	1
Haiku / Sonnet n/g	7/0/3	1,00	2,50	0,19	0,4160	1,0000	0

Axes d'effort










Sol low et medium : les notes gagnent et perdent selon le ticket ; low est plus rapide sur 9/10 et moins cher sur 10/10. Opus low réduit durée et coût, avec une qualité moyenne inférieure (21,45 contre 23,70). Un test non significatif ne justifie pas de dire « à parité ». Les différences inter-cycles peuvent aussi mêler panel et environnement.

Interprétation

Dom. /10 compte les tickets où A est au moins aussi bon sur les trois axes avec une amélioration stricte, pas un test de supériorité. Holm Q porte ici sur toutes les 190 paires des 20 identités, séparément par axe ; les DAG originaux gardent leur famille de 136. Aucune des deux familles ne produit de différence corrigée. Les autres colonnes p sont disponibles dans `appendix-analysis.json`.

Distributions des différences appariées


Dix points par comparaison. $\Delta Q = A-B$; ressources : $\log_2(A/B)$. Zéro = égalité ; à gauche = A plus rapide/moins cher.



Orange : médiane des différences ou des log-ratios. Données par ticket : paired-differences.csv. Aucun intervalle d'équivalence n'est estimé.

Distributions des différences appariées










Dix points par comparaison. $\Delta Q = A-B$; ressources : $\log_2(A/B)$. Zéro = égalité ; à gauche = A plus rapide/moins cher.



Orange : médiane des différences ou des log-ratios. Données par ticket : paired-differences.csv. Aucun intervalle d'équivalence n'est estimé.

Distributions des différences appariées







Dix points par comparaison. $\Delta Q = A-B$; ressources : $\log_2(A/B)$. Zéro = égalité ; à gauche = A plus rapide/moins cher.



Orange : médiane des différences ou des log-ratios. Données par ticket : paired-differences.csv. Aucun intervalle d'équivalence n'est estimé.

Distributions des différences appariées







Dix points par comparaison. $\Delta Q = A - B$; ressources : $\log_2(A/B)$. Zéro = égalité ; à gauche = A plus rapide/moins cher.



Orange : médiane des différences ou des log-ratios. Données par ticket : paired-differences.csv. Aucun intervalle d'équivalence n'est estimé.

Distributions des différences appariées

Dix points par comparaison. $\Delta Q = A-B$; ressources : $\log_2(A/B)$. Zéro = égalité ; à gauche = A plus rapide/moins cher.



Orange : médiane des différences ou des log-ratios. Données par ticket : paired-differences.csv. Aucun intervalle d'équivalence n'est estimé.

Classes de routage : lecture critique de la grille

Groupes repris de skills/route/grid.json ; catégories opérationnelles, non issues d'un clustering statistique.

Classe historique	Séries	Q moy. /30	Minutes moy.	USD moyens
ASSURANCE	d	23,70 - 23,70	9,07 - 9,07	1,558 - 1,558
MILIEU SOLIDE	e2, e3, g, f	21,35 - 22,65	2,09 - 10,58	0,205 - 1,286
ECONOMIQUES	l, n, i, j, k	21,25 - 22,20	5,02 - 60,06	0,039 - 0,305
LOCAL-PRIVE	b2, b3, a	20,60 - 26,20	39,73 - 63,87	0,099 - 0,159
BANNIS	c, c2	8,95 - 10,30	9,15 - 10,21	0,023 - 0,025

Ce que les groupes n'établissent pas

« Assurance » ne garantit pas la fiabilité ; « milieu solide » et « économiques » ont des moyennes de qualité qui se chevauchent. Les modèles locaux ne forment pas une famille homogène : génération, quantification et effort changent. Les libellés « bannis » sont une posture de routage de l'auteur, soutenue par de faibles notes dans ce test, pas une interdiction générale.

Éléments hors classes et notices périmées

b, d2 et e ne sont pas affectés par ces groupes ; mL/mA sont deux périmètres d'une même extension Mistral, pas deux modèles. Les notices de j/k disent encore « rejeu en cours », alors que l'instantané courant est final avec un échec retenu chacun. Le rapport utilise l'instantané, sans modifier silencieusement la politique de routage.

Les 19 événements historiques, en trois classes

141/160 OK et 19 non-OK avant le rejeu b2 ; 142/160 OK et 18 non-OK ensuite. Ne pas confondre tentatives et matrice finale.

Classe initiale	Nombre	Identifiants	Diagnostic et traitement
DNF	4	0874-a, 0874-b3, 0333-j, 0211-k	Plafond 7200 s ; les quatre échecs restent à zéro.
VOID-EMPTY	1	0333-b2	Pause demandée pour libérer le GPU ; archivée ; rejeu 30/30.
VOID-EMPTY	1	0470-c2	Absence de livraison valide ; zéro conservé.
VOID-EMPTY	4	0233-j, 0452-j, 0874-j, 1372-j	Erreurs 403 de quota OpenRouter ; attribution au modèle retirée.
VOID-EMPTY	3	0452-k, 0673-k, 1372-k	Même correction quota ; les rejeux figurent dans la série actuelle.
DNF-PROVIDER	6	h (SpaceBunny)	Endpoint 404, fournisseur indisponible ; série exclue.

Corrections de causalité

Sur les neuf VOID-EMPTY historiques, un est une interruption de l'auteur, sept sont des incidents de quota et un est une absence de livraison retenue. La classe initiale de verdict n'est donc pas une cause. Les six identifiants individuels de h ne sont pas conservés dans les sources publiques consultées : seul leur compte documenté est rapporté.

État actuel

Les cinq échecs retenus dans les séries courantes sont les quatre timeouts et 0470-c2. Le total historique 19 n'est pas le nombre d'échecs du rapport courant. Mistral et Haiku sont des extensions distinctes de cette matrice historique. Source : journal du 6 octobre et ses deux corrections, plus snapshot.json.

Guide de choix : contraintes avant classement

Relu par un relecteur délégué (Fable) à la demande de l'auteur. Ce guide ne vaut ni autorisation de transfert de données ni politique de routage appliquée.

Situation	Choix proposé et limite
Contenu non autorisé à sortir / hors ligne	Local obligatoire dans ce cas ; IQ3_S si la durée convient, sinon différer ou réduire la tâche. Aucun score ne lève la contrainte de confidentialité.
Interaction, résultat attendu vite	Sonnet : 2,09 min en moyenne (médiane 1,13) ; Opus low : 3,03 (2,82) ; Haiku : 6,11 (3,03) ; Luna : 5,02 (3,84). Valeurs observées, pas des délais garantis ; Sonnet et Opus low ne sont pas séparés, même nominalement ($p = 0,16$).
Volume, budget API réduit	Luna : 0,0388 USD en moyenne, 0,0278 en médiane par ticket. Haiku : 0,1257 moyen, 0,0228 médian ; la moyenne porte le risque de queue des longues tâches et du tarif $\times 5$ au-delà de 100 000 tokens de prompt. Écart de coût apparié non significatif même nominalement ($p = 0,36$; Haiku moins cher sur 5/10).
Travail asynchrone, GPU disponible	IQ3_S : 26,20/30, 46,11 min. Préserver un créneau GPU ; le test n'évalue pas le débit multiutilisateur ni une autre machine. Meilleure moyenne locale ; les écarts aux autres séries locales sont nominaux seulement.
GPU occupé	Si le contenu est autorisé, choisir dans les lignes délai ou budget ; sinon attendre. La pause de 0333-b2 est une libération du GPU demandée par l'auteur (rejeu 30/30), pas une défaillance du modèle.
Coût de reprise important	Budgéter toutes les tentatives et le jugement, pas seulement le dernier succès. Mistral mA couvre 26 des 35 tentatives conservées, pas la facture de la campagne. Pour Haiku, le jugement (1,48 USD) a coûté plus que les runs candidats (1,26).

Exemple Haiku/Sonnet : en valorisant le délai linéairement, leurs coûts totaux moyens sont égaux vers 2,66 USD par heure de délai et par ticket (l'erg·h du rapport). Au-dessus, Sonnet est moins cher en coût total valorisé ; au-dessous, Haiku. Cela ignore la différence de qualité (nominale seulement, $p = 0,42$) et n'exprime pas une préférence de l'auteur.

Guide : heures creuses, quotas et disponibilité

Tarification vérifiée le 9 octobre 2026 ; séparer les tarifs du guide et les coûts historiques figés du tournoi.

DeepSeek direct : planifier le flexible

La documentation officielle indique des tarifs creux égaux à la moitié des tarifs pleins. Pics du lundi au vendredi : 01:00-04:00 et 06:00-10:00 UTC, hors jours fériés chinois ; autres heures, week-ends et jours fériés chinois en creux. Utiliser UTC, pas une heure parisienne fixe qui changerait avec l'heure d'été. Pour Flash, entrée hors cache : 0,15/0,30 USD par million, sortie : 0,60/1,20 ; cache lu : 0,003/0,006. Ces tarifs ne s'appliquent pas automatiquement à un revendeur.

Mesure et comptabilité

Les événements par requête ne sont pas réaudités ici. L'heure de fin d'une tâche peut être un proxy imparfait si elle traverse un changement tarifaire. Le guide ne réévalue pas rétroactivement les points du tournoi ; il faut comparer la facture fournisseur à l'estimation du client pour une nouvelle campagne.

Quotas et caps : préserver aussi les juges

Le journal rapporte un manque de crédits OpenAI, un plafond mensuel OpenRouter passé de 40 à 60 USD et un endpoint gratuit retiré. Le plafond OpenRouter a bloqué le panel entier, dont les trois juges utilisaient ce fournisseur. Avant une nouvelle campagne : vérifier crédits, caps, limites de concurrence (DeepSeek : Flash 2 500, Pro 500) et budget des juges ; réserver une marge ; conserver les traces d'incident et distinguer erreur fournisseur et erreur du modèle.

Source officielle DeepSeek (consultée le 9 octobre) : api-docs.deepseek.com/quick_start/pricing/

Provenance et critères de sortie de 1046

Compléments calculés depuis ~/arena (padme) ; l'instantané public donne les mêmes chiffres. Aucun contenu de tâche privée n'est inclus.

Reproduction

Le générateur original appelle tournament-report-completion.py pour ajouter les pages 13-27 dans les deux langues. Les distributions et tests sont recalculés depuis l'instantané produit à partir de ~/arena (snapshot.json) ; appendix-analysis.json conserve toutes les 190 paires et paired-differences.csv les 130 observations des treize comparaisons présentées. Les données numériques de base et les 136 tests par axe des DAG sont inchangés.

Sources et limites de traçabilité

Instantané public figé e352f74... : résultats retenus, audits de tentatives et coûts Mistral/Haiku. Grille : skills/route/grid.json. Hypothèses : ticket 1024, entrée du 5 octobre à 08:40Z. Événements : journal du 6 octobre et corrections. Le 9 octobre, le générateur relancé en mode --arena sur les archives privées (padme) reproduit à l'identique tests.json, comparaisons.csv et toutes les valeurs des séries ; l'instantané public ajoute seulement les métadonnées comptables de Haiku 5.5. La sélection aléatoire et les factures originales ne sont pas réauditées. Les six incidents h sont documentés en nombre, sans identifiants inventés.

État des critères de sortie

Contenu demandé : graphes, grille, verdicts H1/H2, effort, inter-camps, distributions, classes, événements et guide désormais présents. Reproduction publique et finition contrôlées. Le guide a été relu par un relecteur délégué (Fable) sur instruction de l'auteur, et ses corrections appliquées. Ce rapport constitue l'analyse appariée demandée par le parent 1024. Le contenu des tickets d'origine n'est pas exporté.